

Algoritmos Genéticos como Herramienta de Optimización en la Solución Numérica del Modelo No Lineal de Leptospirosis

Análisis del artículo de Sabir et al. (2024) sobre el esquema híbrido ANNs-GA-ASA para la resolución numérica del modelo SIR de Leptospirosis, enfatizando el papel central e indispensable del Algoritmo Genético como motor de búsqueda global y su impacto en la modelización epidemiológica.

Artículo: Sabir, Z., Ali, M. R., Raja, M. A. Z. & Sadat, R. (2024). *Soft Computing*, 28, 607–625

Tema: Cómputo Emergente — Algoritmos Genéticos

Índice

1. Referencia Bibliográfica	2
2. Resumen del Artículo	2
3. Descripción del Problema Abordado	2
3.1. La Leptospirosis como Problema de Salud Pública	2
3.2. El Modelo Matemático SIR de Leptospirosis	3
3.3. Valores de los Parámetros Utilizados	4
3.4. La Dificultad del Problema	5
4. Metodología: El Esquema ANNs-GA-ASA	5
4.1. Diseño de la Red Neuronal Artificial	5
4.2. Función de Aptitud Basada en Errores	6
5. Papel Central del Algoritmo Genético	7
5.1. El GA como Motor de Búsqueda Global	7
5.2. ¿Por qué el GA es indispensable en este problema?	8
5.3. Configuración del GA en el Artículo	9
6. Análisis de Resultados	9
6.1. Soluciones Aproximadas Obtenidas	9
6.2. Comparación con Soluciones de Referencia	10
6.3. Análisis de Error Absoluto (AE)	10
6.4. Análisis Estadístico	10
6.5. Operadores Estadísticos Globales	11
7. Importancia e Impacto de los Algoritmos Genéticos en este Problema	12
7.1. El GA como Habilitador de la Aproximación Neural	12
7.2. Impacto en la Modelización de Enfermedades Infecciosas	12
7.3. Comparación con Enfoques Alternativos	13
7.4. Relevancia del GA en el Contexto de la Computación Emergente	13
8. Análisis Crítico: Ventajas y Limitaciones	13
8.1. Ventajas del Método ANNs-GA-ASA	13
8.2. Limitaciones del Método	14
9. Conclusiones Personales	14
Referencias	15

1. Referencia Bibliográfica

Sabir, Z., Ali, M. R., Raja, M. A. Z., & Sadat, R. (2024). An efficient computational procedure to solve the biological nonlinear Leptospirosis model using the genetic algorithms. *Soft Computing*, 28, 607–625. <https://doi.org/10.1007/s00500-023-08315-5>

2. Resumen del Artículo

El artículo de Sabir et al. (2024) presenta un procedimiento computacional eficiente para resolver numéricamente el modelo matemático no lineal de la enfermedad de Leptospirosis (LD) mediante la combinación de Redes Neuronales Artificiales (ANNs) con un esquema de optimización híbrido basado en el Algoritmo Genético (GA) como búsqueda global y el Algoritmo Active-Set (ASA) como refinamiento local, denominado **ANNs-GA-ASA**. La Leptospirosis es una enfermedad zoonótica de distribución mundial transmitida por roedores, que constituye una causa significativa de mortalidad en poblaciones humanas expuestas a aguas contaminadas.

El modelo matemático de la Leptospirosis se basa en la estructura epidemiológica SIR (Susceptible-Infectado-Recuperado) y comprende un sistema de cinco ecuaciones diferenciales ordinarias no lineales que describen la dinámica de propagación de la enfermedad tanto en la población humana como en la población roedora. La función de aptitud se construye a partir de los errores residuales del sistema diferencial, y su minimización se logra mediante la hibridación GA-ASA, donde el GA realiza la exploración global del espacio de parámetros y el ASA refina la solución localmente.

Los resultados obtenidos por ANNs-GA-ASA se compararon con soluciones de referencia calculadas mediante el método de Runge-Kutta, mostrando una coincidencia de nivel 6 a 9. El análisis estadístico, que incluye los operadores VAF (Variance Account For), TIC (Theil's Inequality Coefficient), MAD (Mean Absolute Deviation) y SIR (Semi-Interquartile Range), confirmó la precisión, exactitud y convergencia del esquema propuesto, con errores absolutos del orden de 10^{-4} a 10^{-7} en las mejores ejecuciones.

3. Descripción del Problema Abordado

3.1. La Leptospirosis como Problema de Salud Pública

La Leptospirosis es una enfermedad bacteriana zoonótica de carácter global que se transmite a los humanos a través del contacto con orina de animales infectados, particularmente roedores, que contaminan el agua y el suelo. Las bacterias del género *Leptospira* pueden ingresar al organismo humano a través de heridas en la piel o mucosas expuestas a alimentos, suelo o agua contaminados (Bhalraj & Azmi, 2019). Los brotes de LD ocurren de forma súbita, especialmente durante inundaciones, cuando las poblaciones utilizan agua contaminada (Triampo et al., 2007).

Las fuentes principales de la bacteria incluyen ganado bovino, ovejas, cerdos, perros, cabras, caballos, ratas, mapaches y ratones (Goh et al., 2019). La tasa de transmisión de persona a persona es muy baja, lo que convierte al control de la población roedora y la prevención de la exposición en las estrategias fundamentales de salud pública (El-Shahed, 2014). La modelización matemática de la dinámica de propagación de la enfermedad es

esencial para predecir brotes, evaluar estrategias de intervención y optimizar la asignación de recursos sanitarios.

3.2. El Modelo Matemático SIR de Leptospirosis

El modelo de Leptospirosis utilizado en el artículo se basa en la estructura epidemiológica SIR (Susceptible-Infectado-Recuperado) extendida a dos poblaciones: humana y roedora. El sistema comprende cinco clases de individuos:

Tabla 1: Clases del modelo SIR de Leptospirosis

Clase	Descripción
$S_h(s)$	Humanos susceptibles
$I_h(s)$	Humanos infectados
$R_h(s)$	Humanos recuperados
$S_r(s)$	Ratones susceptibles
$I_r(s)$	Ratones infectados

El sistema de ecuaciones diferenciales ordinarias que gobierna la dinámica del modelo es:

$$\frac{dS_h}{ds} = \Lambda - \beta_h S_h I_r - \lambda_h S_h + h_h R_h, \quad S_h(0) = I_1 \quad (1)$$

$$\frac{dI_h}{ds} = \beta_h S_h I_r - (\lambda_h + d_h + r_h) I_h, \quad I_h(0) = I_2 \quad (2)$$

$$\frac{dR_h}{ds} = r_h I_h - (\lambda_h + h_h) R_h, \quad R_h(0) = I_3 \quad (3)$$

$$\frac{dS_r}{ds} = B - \beta_r S_r I_r - \lambda_r S_r, \quad S_r(0) = I_4 \quad (4)$$

$$\frac{dI_r}{ds} = \beta_r S_r I_r - (\lambda_r + d_r) I_r, \quad I_r(0) = I_5 \quad (5)$$

donde los parámetros del modelo se detallan en la siguiente tabla:

Tabla 2: Parámetros del modelo de Leptospirosis

Parámetro	Descripción
Λ	Tasa de reclutamiento de la población humana
λ_h	Tasa natural de muerte de la población humana
β_h	Tasa de transmisión LD de infectado a susceptible (rata $\rightarrow$ humano)
h_h	Tasa de individuos inmunes que vuelven a ser susceptibles
d_h	Tasa de muerte de humanos infectados por la enfermedad
r_h	Tasa de recuperación humana
B	Tasa de reclutamiento de la población de ratas
λ_r	Tasa de muerte natural de la población de ratas
β_r	Tasa de transmisión LD de infectado a susceptible (rata $\rightarrow$ rata)
d_r	Tasa de muerte de ratas infectadas




Figura 1: Diagrama de flujo del modelo SIR de Leptospirosis mostrando las transiciones entre compartimentos humanos (azul) y roedores (rojo). La transmisión cruzada roedor-humano se indica con flecha discontinua.

3.3. Valores de los Parámetros Utilizados

El artículo utiliza los siguientes valores numéricos para los parámetros del modelo, derivados de estudios epidemiológicos previos:

Tabla 3: Valores numéricos de los parámetros del modelo

Parámetro	Valor	Parámetro	Valor
Λ	1.6	B	1.2
λ_h	0.034	λ_r	0.17
β_h	0.0098	β_r	0.078
h_h	0.0067	d_r	0.094
d_h	0.0001		
r_h	0.007		

Condiciones iniciales: $S_h(0) = 100$, $I_h(0) = 20$, $R_h(0) = 30$, $S_r(0) = 50$, $I_r(0) = 10$.




Figura 2: Dinámica poblacional del modelo SIR de Leptospirosis obtenida mediante simulación numérica con los parámetros del artículo. Izquierda: población humana. Derecha: población roedora.

3.4. La Dificultad del Problema

La resolución numérica de este sistema presenta desafíos significativos. Las ecuaciones son **no lineales** debido a los términos de interacción $\beta_h S_h I_r$ y $\beta_r S_r I_r$, que acoplan las poblaciones susceptible e infectada. Esta no linealidad impide obtener soluciones analíticas cerradas y hace que los métodos numéricos tradicionales (como Euler o Runge-Kutta) requieran pasos de integración pequeños y condiciones de estabilidad específicas. Además, la sensibilidad del modelo a los parámetros epidemiológicos y la necesidad de capturar la dinámica transitoria completa del sistema motivan la exploración de enfoques computacionales más sofisticados, como los basados en redes neuronales y metaheurísticas.

4. Metodología: El Esquema ANNs-GA-ASA

4.1. Diseño de la Red Neuronal Artificial

El método propuesto utiliza redes neuronales artificiales (ANNs) como aproximadores universales de las soluciones del sistema diferencial. Cada clase del modelo LD (S_h , I_h , R_h , S_r , I_r) se aproxima mediante una red neuronal feedforward con una capa oculta de 10 neuronas y función de activación log-sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (6)$$

La aproximación para cada variable de estado toma la forma:

$$\hat{S}_h(s) = \sum_{i=1}^m q_{S_h,i} \cdot \frac{1}{1 + e^{-(w_{S_h,i} \cdot s + v_{S_h,i})}} \quad (7)$$

y análogamente para $\hat{I}_h(s)$, $\hat{R}_h(s)$, $\hat{S}_r(s)$ e $\hat{I}_r(s)$, donde $m = 10$ es el número de neuronas ocultas. Los parámetros a optimizar son los pesos de la red: coeficientes de salida (q), pesos de entrada (w) y sesgos (v), lo que resulta en un total de **30 variables** por cada clase ($5 \text{ clases} \times 10 \text{ neuronas} \times 3 \text{ parámetros} = 150 \text{ parámetros totales}$, organizados como 30 variables por la estructura vectorial).

4.2. Función de Aptitud Basada en Errores

La función de aptitud (fitness) se construye a partir de los errores residuales del sistema diferencial. Para N puntos de evaluación en el intervalo $[0, 1]$, se definen cinco componentes de error:

$$e_1 = \frac{1}{N} \sum_{i=1}^N [\hat{S}'_h - \Lambda + \lambda_h \hat{S}_h + \beta_h \hat{I}_r \hat{S}_h - h_h \hat{R}_h]^2 \quad (8)$$

$$e_2 = \frac{1}{N} \sum_{i=1}^N [\hat{I}'_h - \beta_h \hat{I}_r \hat{S}_h + (\lambda_h + d_h + r_h) \hat{I}_h]^2 \quad (9)$$

$$e_3 = \frac{1}{N} \sum_{i=1}^N [\hat{R}'_h - r_h \hat{I}_h + (\lambda_h + h_h) \hat{R}_h]^2 \quad (10)$$

$$e_4 = \frac{1}{N} \sum_{i=1}^N [\hat{S}'_r - B + \lambda_r \hat{S}_r + \beta_r \hat{S}_r \hat{I}_r]^2 \quad (11)$$

$$e_5 = \frac{1}{N} \sum_{i=1}^N [\hat{I}'_r - \beta_r \hat{S}_r \hat{I}_h + (\lambda_r + d_r) \hat{I}_r]^2 \quad (12)$$

La función de aptitud total es la suma ponderada:

$$e = e_1 + e_2 + e_3 + e_4 + e_5 \quad (13)$$

donde se incluyen además términos de penalización para las condiciones iniciales:

$$e += \frac{1}{2} [(\hat{S}_h(0) - 100)^2 + (\hat{I}_h(0) - 20)^2 + (\hat{R}_h(0) - 30)^2 + (\hat{S}_r(0) - 50)^2 + (\hat{I}_r(0) - 10)^2] \quad (14)$$

El objetivo de la optimización es **minimizar** esta función de aptitud e , de modo que la red neuronal aproxime con la mayor precisión posible las soluciones verdaderas del sistema diferencial, satisfaciendo simultáneamente las ecuaciones del modelo y las condiciones iniciales.

5. Papel Central del Algoritmo Genético

5.1. El GA como Motor de Búsqueda Global

El Algoritmo Genético desempeña el papel más importante en todo el esquema ANNs-GA-ASA: es el responsable de la exploración global del espacio de búsqueda de los **30 parámetros (pesos) de la red neuronal**. Sin el GA, el método carecería de la capacidad de escapar de mínimos locales en un espacio de parámetros de alta dimensionalidad y fuertemente no lineal. Esta es la contribución algorítmica fundamental del artículo y la razón por la cual el GA aparece en el título del trabajo.

El GA opera sobre una población de cromosomas, donde cada cromosoma codifica un conjunto completo de pesos de la red neuronal. A través de operadores de selección, cruce y mutación, el GA evoluciona la población a lo largo de múltiples generaciones para encontrar la configuración de pesos que minimice la función de aptitud. El proceso es el siguiente:

1. **Inicialización:** Se genera una población aleatoria de cromosomas, donde cada cromosoma contiene los 30 parámetros de la red neuronal.
2. **Evaluación:** Se calcula la función de aptitud e para cada cromosoma evaluando qué tan bien la red neuronal correspondiente satisface el sistema diferencial.
3. **Selección:** Los cromosomas con menor error (mayor aptitud) tienen mayor probabilidad de ser seleccionados como padres, siguiendo el principio de supervivencia del más apto.
4. **Cruce:** Se combinan segmentos de cromosomas padres para generar descendientes, explorando nuevas regiones del espacio de parámetros mediante la recombinación de información genética favorable.
5. **Mutación:** Se introducen perturbaciones aleatorias en los genes de los descendientes para mantener la diversidad poblacional y evitar la convergencia prematura a mínimos locales.
6. **Reemplazo:** La nueva generación reemplaza a la anterior, y el ciclo se repite hasta que se satisface el criterio de convergencia.




Figura 3: Diagrama de flujo del método ANNs-GA-ASA. El Algoritmo Genético (bloque amarillo) constituye la etapa central de búsqueda global, mientras que el Active-Set Algorithm (bloque púrpura) refina localmente la solución encontrada por el GA.

5.2. ¿Por qué el GA es indispensable en este problema?

La necesidad del Algoritmo Genético en la resolución del modelo de Leptospirosis se fundamenta en las siguientes razones:

1. Espacio de búsqueda de alta dimensionalidad y no linealidad. El sistema requiere optimizar 30 variables continuas (pesos de la red neuronal) en un espacio donde la función de aptitud es altamente no lineal y multimodal, con múltiples mínimos locales. Los métodos de optimización basados en gradiente tienden a quedar atrapados en estos mínimos locales, mientras que el GA, como método estocástico basado en población, puede escapar de ellos mediante diversidad genética y operadores de variación.

2. Ausencia de información de gradiente. La función de aptitud se construye a partir de los residuos de un sistema de EDOs no lineales evaluados numéricamente. No existe una expresión analítica para el gradiente de e respecto a los pesos de la red neuronal, lo que imposibilita el uso directo de métodos de descenso de gradiente convencionales. El GA no requiere información de gradiente, lo que lo hace ideal para este tipo de problemas de “caja negra”.

3. Robustez frente a la estructura del problema. El GA puede manejar funciones objetivo no convexas, no diferenciables y con ruido numérico, características comunes en problemas de aproximación de sistemas diferenciales. Su naturaleza poblacional le permite mantener múltiples hipótesis simultáneamente sobre la solución, reduciendo la dependencia del punto de inicialización.

4. Capacidad de exploración global. A diferencia de los métodos de búsqueda local que exploran una vecindad del punto actual, el GA explora simultáneamente múltiples regiones del espacio de parámetros gracias a su población de soluciones. Esto es crucial cuando el óptimo global se encuentra en una cuenca de atracción distinta a la del punto de partida.

5. Complementariedad con la búsqueda local (ASA). El GA proporciona una solución aproximada de alta calidad que sirve como punto de partida para el algoritmo Active-Set (ASA), que realiza un refinamiento local preciso. Esta hibridación GA-ASA combina las ventajas de la exploración global del GA con la explotación eficiente del ASA, resultando en un esquema de optimización más robusto y preciso que cualquiera de los dos métodos por separado.

5.3. Configuración del GA en el Artículo

El artículo ejecuta el GA durante 20 ejecuciones independientes para garantizar la reproducibilidad estadística de los resultados. En cada ejecución, el GA optimiza los 30 parámetros de la red neuronal buscando minimizar la función de aptitud e . Los mejores pesos obtenidos por el GA se refinan posteriormente con el ASA.




Figura 4: Curva de convergencia ilustrativa del Algoritmo Genético en el esquema ANNs-GA-ASA. La línea azul muestra la evolución del mejor individuo, mientras que la roja muestra el promedio poblacional. La línea verde indica el punto donde el ASA comienza el refinamiento local.

6. Análisis de Resultados

6.1. Soluciones Aproximadas Obtenidas

Tras 20 ejecuciones independientes del esquema ANNs-GA-ASA, se obtuvieron los mejores pesos de la red neuronal que permiten reconstruir las soluciones aproximadas del

modelo LD. Las expresiones resultantes para $S_h(s)$ e $I_h(s)$ se presentan como combinaciones lineales de 10 funciones log-sigmoid con los parámetros optimizados. Por ejemplo, la solución para $S_h(s)$ se expresa como:

$$\hat{S}_h(s) = \frac{10,1686}{1 + e^{-(2,0340s+0,6797)}} + \frac{11,9962}{1 + e^{-(1,6731s-4,2375)}} + \dots \quad (15)$$

(con 10 términos en total). Las soluciones para las demás clases siguen la misma estructura con sus respectivos pesos optimizados.

6.2. Comparación con Soluciones de Referencia

Las soluciones ANNs-GA-ASA se compararon con las soluciones de referencia obtenidas mediante el método de Runge-Kutta de orden 4. La comparación mostró que las curvas se superponen casi perfectamente, con un nivel de coincidencia de 6 a 9, lo que indica la alta precisión del método propuesto.

6.3. Análisis de Error Absoluto (AE)

Los valores de Error Absoluto (AE) para cada clase del modelo se resumen a continuación:

Tabla 4: Errores absolutos por clase del modelo

Clase	AE Medio	AE Mejor
$\hat{S}_h(s)$	$10^{-4} - 10^{-5}$	$10^{-5} - 10^{-7}$
$\hat{I}_h(s)$	$10^{-4} - 10^{-5}$	$10^{-4} - 10^{-6}$
$\hat{R}_h(s)$	$10^{-4} - 10^{-5}$	$10^{-5} - 10^{-7}$
$\hat{S}_r(s)$	$10^{-3} - 10^{-4}$	$10^{-4} - 10^{-6}$
$\hat{I}_r(s)$	$10^{-4} - 10^{-5}$	$10^{-5} - 10^{-7}$

Estos errores son extremadamente pequeños, lo que demuestra que el esquema ANNs-GA-ASA es capaz de aproximar las soluciones del sistema no lineal de Leptospirosis con una precisión comparable a los métodos numéricos clásicos, pero con la ventaja de proporcionar una representación funcional continua de la solución.

6.4. Análisis Estadístico

El artículo presenta un análisis estadístico exhaustivo para validar la precisión y estabilidad del método. Los operadores estadísticos utilizados incluyen:

VAF (Variance Account For): Mide el porcentaje de variabilidad de las soluciones de referencia que es explicado por las soluciones aproximadas. Valores cercanos a 100 % indican buena aproximación.

$$\text{VAF} = \left(1 - \frac{\text{var}(y_{\text{ref}} - \hat{y})}{\text{var}(y_{\text{ref}})} \right) \times 100 \quad (16)$$

TIC (Theil's Inequality Coefficient): Mide la desigualdad entre las series de referencia y aproximadas. Valores cercanos a 0 indican buena aproximación.

$$\text{TIC} = \frac{\sqrt{\frac{1}{N} \sum (y_{\text{ref}} - \hat{y})^2}}{\sqrt{\frac{1}{N} \sum y_{\text{ref}}^2} + \sqrt{\frac{1}{N} \sum \hat{y}^2}} \quad (17)$$

MAD (Mean Absolute Deviation): Mide la desviación media absoluta entre las soluciones de referencia y aproximadas.

SIR (Semi-Interquartile Range): Mide la dispersión estadística de los resultados a lo largo de las 20 ejecuciones.

Los resultados de los operadores estadísticos para cada clase se presentan en la siguiente tabla:

Tabla 5: Operadores estadísticos por clase (mejor ejecución)

Clase	EVAF (Mejor)	TIC (Mejor)	MAD (Mejor)
$\hat{S}_h(s)$	$10^{-11} - 10^{-12}$	$10^{-8} - 10^{-10}$	$10^{-5} - 10^{-6}$
$\hat{I}_h(s)$	$10^{-11} - 10^{-12}$	$10^{-8} - 10^{-10}$	$10^{-5} - 10^{-6}$
$\hat{R}_h(s)$	$10^{-11} - 10^{-12}$	$10^{-8} - 10^{-10}$	$10^{-5} - 10^{-6}$
$\hat{S}_r(s)$	$10^{-11} - 10^{-12}$	$10^{-8} - 10^{-10}$	$10^{-5} - 10^{-6}$
$\hat{I}_r(s)$	$10^{-11} - 10^{-12}$	$10^{-8} - 10^{-10}$	$10^{-5} - 10^{-6}$

6.5. Operadores Estadísticos Globales

Los operadores globales evaluados sobre las 20 ejecuciones independientes proporcionan una medida de la consistencia del método:

Tabla 6: Operadores estadísticos globales (media de 20 ejecuciones)

Clase	G.MAD (Media)	G.TIC (Media)	G.EVAF (Media)
$\hat{S}_h(s)$	$8,41 \times 10^{-5}$	$4,74 \times 10^{-9}$	$2,08 \times 10^{-10}$
$\hat{I}_h(s)$	$6,94 \times 10^{-5}$	$3,82 \times 10^{-9}$	$1,91 \times 10^{-10}$
$\hat{R}_h(s)$	$6,47 \times 10^{-5}$	$3,43 \times 10^{-9}$	$1,29 \times 10^{-10}$
$\hat{S}_r(s)$	$6,47 \times 10^{-5}$	$4,47 \times 10^{-9}$	$2,12 \times 10^{-10}$
$\hat{I}_r(s)$	$5,66 \times 10^{-5}$	$2,99 \times 10^{-9}$	$9,08 \times 10^{-11}$

Los valores extremadamente pequeños de G.TIC (del orden de 10^{-9}) y G.EVAF (del orden de 10^{-10}) confirman la **convergencia, precisión y estabilidad** del esquema ANNs-GA-ASA a lo largo de múltiples ejecuciones, lo que valida la robustez del Algoritmo Genético como motor de optimización.

7. Importancia e Impacto de los Algoritmos Genéticos en este Problema

7.1. El GA como Habilitador de la Aproximación Neural

La contribución más significativa del Algoritmo Genético en este trabajo es su rol como **habilitador de la aproximación por redes neuronales**. Sin un método de optimización capaz de encontrar los pesos adecuados de la red neuronal, la representación funcional del modelo de Leptospirosis sería imposible. El GA proporciona precisamente esta capacidad: dado que la función de aptitud es una “caja negra” no diferenciable construida a partir de residuos de EDOs, los métodos tradicionales de optimización basados en gradiente son inadecuados o ineficientes. El GA, al ser un método libre de gradiente y basado en población, puede explorar efectivamente el espacio de 30 dimensiones de los pesos de la red neuronal.

7.2. Impacto en la Modelización de Enfermedades Infecciosas

El enfoque ANNs-GA-ASA tiene un impacto potencialmente transformador en la modelización epidemiológica por varias razones:

1. **Soluciones funcionales continuas:** A diferencia de los métodos numéricos clásicos (Euler, Runge-Kutta) que producen soluciones discretas en puntos específicos, el esquema ANNs-GA-ASA genera una **representación funcional continua** de la solución, lo que permite evaluar el modelo en cualquier punto del dominio sin necesidad de interpolación.
2. **Generalización a modelos complejos:** La metodología es escalable y puede aplicarse a modelos epidemiológicos más complejos (SEIR, SEIRS, modelos con vacunación, modelos con estructura de edad) simplemente modificando la función de aptitud, sin cambiar la infraestructura de optimización.
3. **Aplicabilidad a modelos de orden fraccional:** Los autores señalan que el esquema ANNs-GA-ASA es capaz de resolver modelos de orden fraccional, que son más adecuados para capturar efectos de “memoria larga” en la dinámica de enfermedades infecciosas.
4. **Herramienta para análisis de sensibilidad paramétrica:** La naturaleza estocástica del GA y las múltiples ejecuciones independientes permiten evaluar la sensibilidad de las soluciones a los parámetros del modelo, información crucial para los epidemiólogos.

7.3. Comparación con Enfoques Alternativos

Tabla 7: Comparación de enfoques para la resolución del modelo de Leptospirosis

Enfoque	Ventajas	Desventajas
Runge-Kutta	Estándar bien establecido, fácil implementación	Soluciones discretas, dependencia del paso, dificultad con sistemas rígidos
Métodos analíticos	Soluciones exactas cuando existen	No aplicables a sistemas no lineales complejos
ANNs con gradiente	Convergencia rápida cuando el gradiente está disponible	Requieren diferenciabilidad, riesgo de mínimos locales
ANNs-GA-ASA	Libre de gradiente, exploración global, soluciones continuas, robustez estadística	Mayor costo computacional, dependencia de hiperparámetros del GA

7.4. Relevancia del GA en el Contexto de la Computación Emergente

En el marco de la computación emergente, el uso del Algoritmo Genético como herramienta de optimización en problemas biomatemáticos ilustra un paradigma fundamental: **la sinergia entre métodos bioinspirados y problemas biológicos**. El GA, inspirado en la evolución natural por selección darwiniana, se aplica a la resolución de un modelo que describe precisamente la propagación de un agente biológico (la bacteria *Leptospira*). Esta correspondencia entre el método computacional y la naturaleza del problema no es casual: los sistemas biológicos han evolucionado durante millones de años para resolver problemas de optimización complejos (adaptación, supervivencia, propagación), y los algoritmos que imitan estos procesos naturales son particularmente adecuados para modelarlos y resolverlos.

El impacto práctico de esta sinergia se manifiesta en la capacidad de predecir brotes de Leptospirosis con mayor precisión, evaluar escenarios de intervención (como campañas de vacunación o control de roedores), y optimizar la asignación de recursos de salud pública. Estas capacidades son especialmente relevantes en regiones tropicales y subtropicales donde la Leptospirosis es endémica y los recursos sanitarios son limitados.

8. Análisis Crítico: Ventajas y Limitaciones

8.1. Ventajas del Método ANNs-GA-ASA

- Exploración global efectiva:** El GA evita el atrapamiento en mínimos locales que plaga a los métodos de optimización basados en gradiente, explorando múltiples regiones del espacio de parámetros simultáneamente.
- Libertad de gradiente:** No requiere el cálculo de derivadas de la función de aptitud, lo que lo hace aplicable a una amplia clase de problemas de “caja negra” donde la función objetivo es compleja o no diferenciable.
- Hibridación GA-ASA:** La combinación de búsqueda global (GA) con refinamiento local (ASA) produce soluciones más precisas que cualquiera de los dos métodos

por separado. El GA encuentra la cuenca de atracción del óptimo global, y el ASA converge rápidamente al óptimo dentro de esa cuenca.

4. **Validación estadística robusta:** Las 20 ejecuciones independientes y el análisis mediante múltiples operadores estadísticos (VAF, TIC, MAD, SIR) proporcionan una evaluación rigurosa de la precisión y estabilidad del método.
5. **Soluciones funcionales continuas:** La representación de la solución como una función analítica (combinación de sigmoides) permite evaluación en cualquier punto del dominio y facilita el cálculo de derivadas.
6. **Escalabilidad:** La arquitectura modular permite extender el método a modelos con más ecuaciones o diferentes estructuras epidemiológicas.

8.2. Limitaciones del Método

1. **Costo computacional elevado:** El GA requiere evaluar la función de aptitud para múltiples individuos a lo largo de muchas generaciones, lo que implica resolver numéricamente el sistema de EDOs repetidamente. Esto hace que el método sea significativamente más costoso que los métodos numéricos directos.
2. **Sensibilidad a los hiperparámetros:** El rendimiento del GA depende de la elección de hiperparámetros como el tamaño de población, la probabilidad de cruce, la probabilidad de mutación y el número de generaciones. El artículo no detalla extensivamente estos parámetros ni realiza un análisis de sensibilidad algorítmica.
3. **Falta de garantías de convergencia teórica:** Como todo método metaheurístico, el GA no garantiza encontrar el óptimo global en un número finito de evaluaciones. La convergencia depende de la configuración del algoritmo y la estructura del problema.
4. **Dependencia de la arquitectura de la red neuronal:** La elección de 10 neuronas ocultas y la función de activación log-sigmoid es empírica. No se presenta un análisis sistemático de cómo afecta la arquitectura de la red a la calidad de la aproximación.
5. **Comparación limitada:** Los resultados se comparan únicamente con las soluciones de Runge-Kutta. No se compara con otros métodos de aproximación neural (como PINNs — Physics-Informed Neural Networks) ni con otros metaheurísticos (como PSO, DE, o algoritmos de colonia de hormigas).
6. **Modelo simplificado:** El modelo SIR utilizado no incorpora factores como la estacionalidad, la heterogeneidad espacial, la estructura de edad, ni las intervenciones de salud pública, lo que limita su aplicabilidad directa a escenarios epidemiológicos reales.

9. Conclusiones Personales

El artículo de Sabir et al. (2024) demuestra de manera convincente que los Algoritmos Genéticos constituyen una herramienta poderosa y esencial para la resolución numérica de modelos epidemiológicos no lineales como el de la Leptospirosis. El GA no es un complemento menor en el esquema ANNs-GA-ASA, sino su componente central: sin la

capacidad de exploración global del GA, la red neuronal no podría encontrar los pesos adecuados para aproximar las soluciones del sistema diferencial, y el refinamiento local del ASA carecería de un punto de partida de calidad.

La importancia del GA en este contexto trasciende lo puramente algorítmico. Su capacidad de operar sin información de gradiente, de manejar funciones objetivo no convexas y multimodales, y de mantener diversidad poblacional lo convierte en el método de optimización más adecuado para la clase de problemas que presenta la modelización epidemiológica, donde la función de aptitud se construye a partir de residuales de sistemas de EDOs no lineales.

El impacto potencial de esta metodología en la salud pública es considerable: la capacidad de obtener soluciones funcionales continuas de modelos de enfermedades infecciosas, con validación estadística rigurosa, abre la puerta a herramientas computacionales más precisas para la predicción de brotes y la evaluación de estrategias de intervención. Sin embargo, es necesario reconocer que la transición del ámbito académico al aplicado requiere abordar las limitaciones identificadas, particularmente en cuanto al costo computacional y la extensión a modelos epidemiológicos más realistas.

Desde la perspectiva de la computación emergente, este trabajo ilustra un principio fundamental: **los algoritmos bioinspirados son particularmente efectivos para resolver problemas de naturaleza biológica**, no por casualidad, sino porque ambos — el algoritmo y el problema — comparten una misma lógica subyacente de optimización bajo restricciones complejas. El GA, como emulación computacional de la evolución natural, es el puente metodológico que permite traducir la complejidad biológica de la Leptospirosis en soluciones numéricas precisas y confiables.

Referencias

- Bhalraj, A., & Azmi, A. (2019). Mathematical modelling of the spread of Leptospirosis. *AIP Conference Proceedings*, 2184(1), 060031.
- El-Shahed, M. (2014). Fractional order model for the spread of Leptospirosis. *International Journal of Mathematical Analysis*, 8(54), 2651–2667.
- Goh, S. H., et al. (2019). Risk factors and prediction of leptospiral seropositivity among dogs and dog handlers in Malaysia. *International Journal of Environmental Research and Public Health*, 16(9), 1499.
- Keeling, M. J. (2001). Mathematics and biology. *The Mathematical Gazette*, 85(502), 6–16.
- Khan, M. A., et al. (2016). Dynamical behavior of Leptospirosis disease with saturated incidence rate. *International Journal of Biomathematics*, 9(03), 1650034.
- Sabir, Z., Ali, M. R., Raja, M. A. Z., & Sadat, R. (2024). An efficient computational procedure to solve the biological nonlinear Leptospirosis model using the genetic algorithms. *Soft Computing*, 28, 607–625.
- Thayaparan, S., et al. (2013). Leptospirosis, an emerging zoonotic disease in Malaysia. *Malaysian Journal of Pathology*, 35(2), 123–132.

- Triampo, W., et al. (2007). A simple deterministic model for the spread of Leptospirosis in Thailand. *International Journal of Biomedical Science*, 2, 22–26.